

引文格式:

金星亮, 万程, 谢晨杰, 等. 基于多参数特征融合的无袖带连续血压测量方法 [J]. 集成技术, 2023, 12(2): 29-38.

Jin XL, Wan C, Xie CJ, et al. Cuffless continuous blood pressure measurement method based on multi-parameter feature fusion [J]. Journal of Integration Technology, 2023, 12(2): 29-38.

基于多参数特征融合的无袖带连续血压测量方法

金星亮¹ 万程² 谢晨杰^{2,3} 刘三超¹ 吴丹^{2*}

¹(深圳迈瑞生物医疗电子股份有限公司 深圳 518057)

²(中国科学院深圳先进技术研究院 深圳 518055)

³(南方科技大学 深圳 518055)

摘 要 血压是人体的生理指标, 连续测量患者每个心动周期的动脉血压数据, 是医护人员对患者实时诊断的重要依据。现有的无袖带连续血压测量方法, 大多基于脉搏波和心电图两路信号获取特征并进行预测建模, 无法涵盖影响血压的多种因素, 模型存在一定误差。该文对 55 位志愿者进行实验, 在传统脉搏波和心电信号的基础上, 引入心阻抗图等体征信息, 探索影响血压测量精度的因素。实验结果表明, 基于多参数特征融合的随机森林模型的性能优于基于单个特征的线性模型, 其对于收缩压和舒张压预测的平均绝对误差分别为 2.56 mmHg、1.91 mmHg。该实验证明了基于多特征融合的无袖带血压预测模型可提高血压预测的精度。

关键词 连续血压; 无袖带; 多参数; 机器学习; 心阻抗图

中图分类号 TP 181 文献标志码 A doi: 10.12146/j.issn.2095-3135.20221116001

Cuffless Continuous Blood Pressure Measurement Method Based on Multi-parameter Feature Fusion

JIN Xingliang¹ WAN Cheng² XIE Chenjie^{2,3} LIU Sanchao¹ WU Dan^{2*}

¹(Shenzhen Mindray Bio-Medical Electronics Co., Ltd., Shenzhen 518057, China)

²(Shenzhen Institute of Advanced Technology, Chinese Academy of Sciences, Shenzhen 518055, China)

³(Southern University of Science and Technology, Shenzhen 518055, China)

*Corresponding Author: dan.wu@siat.ac.cn

Abstract Blood pressure is a physiological indicator of human body. Continuous measurement of arterial blood pressure in each cardiac cycle is an important basis for real time diagnoses. Most of the cuffless

收稿日期: 2022-11-16 修回日期: 2022-12-19

基金项目: 国家自然科学基金青年基金项目(81701788); 广东省自然科学基金面上项目(2022A1515011217)

作者简介: 金星亮, 硕士, 研究方向为生理信号检测; 万程, 硕士研究生, 研究方向为机器学习; 谢晨杰, 硕士研究生, 研究方向为生物医学建模; 刘三超, 硕士, 研究方向为生理信号分析算法; 吴丹(通讯作者), 高级工程师, 研究方向为可穿戴传感与智能计算, E-mail: dan.wu@siat.ac.cn.

continuous blood pressure measurements are performed according to the predictive models based on the pulse wave and electrocardiogram signals. However, they may produce errors due to the limited measurements. In this paper, multiple physical signs, such as impedance cardiogram, are explored to improve the measured accuracy of blood pressure. Experiments were conducted upon 55 volunteers, and results show that the random forest model based on multi-parameter feature fusion outperformed the linear model based on a single feature, with mean absolute errors of 2.56 mmHg and 1.91 mmHg for the prediction of systolic and diastolic blood pressure, respectively. It proves that the proposed cuffless blood pressure prediction model based on the multi-feature fusion could improve the accuracy of blood pressure prediction.

Keywords continuous blood pressure; cuffless; multi-parameter; machine learning; impedance cardiogram

Funding This work is support by National Natural Science Foundation of China (81701788) and General Program of Natural Science Foundation of Guangdong Province, China (2022A1515011217)

Ethical Statement The study was approved by the Institutional Review Board of the Shenzhen Institute of Advanced Technology, Chinese Academy of Sciences (ID number: SIAT-IRB-181215-H0274)

1 引言

血压作为人体重要的生理参数,可实时反映人体的生理健康状况,是评估心脏和血管功能健康状况的重要依据。大量临床研究表明,在围术期进行连续血压监测具有十分重要的意义^[1-2]。在手术或危重患者中,低血压症状较为常见^[3],研究表明,当平均动脉压降低至 80 mmHg 持续 10 min 时,可能导致器官损伤,且该损伤随着时间的持续而加重^[4-5],因此,手术室及重症监护室的患者更需要进行连续血压监测。临床上常用的连续血压测量方法需要动脉内插管,该方法不仅具有有创性,而且极易引起并发症。有研究表明对非心脏手术患者进行血压监测,在有创动脉血压监测组中,29.1% 的患者发生了心肌损伤,与采用无创血压监测的患者相比,有创动脉血压监测的患者术后 72 h 内心肌损伤发病率更高^[6]。然而,传统袖带式的无创血压测量无法做到持续监测,对于病情变化迅速的患者,由于不能及时监测血压波动,从而对患者的生命安全造成影响。因此,探索一种连续的血压测量方法,对于

临床体征监测或家庭健康监测都具有十分重要的意义。

目前,基于动脉张力法及容积补偿法的连续血压测量理论较为成熟,但是前者对传感器的精度及定位要求较高,后者长时间测量则会导致静脉充血,从而影响测量精度。基于 Moens-Korteweg 公式的脉搏波传导时间(Pulse Transmit Time, PTT)血压估计方法由于可以彻底摆脱袖带和指套,引起了广泛关注。然而,该模型进行血压监测时需要校准,且测量精度较差。为提高测量精度,有学者致力于探寻新的血压关联因子,在传统脉搏波传导时间模型的基础上,引入与血压相关的重要因子,如心率变异性^[7]、脉搏宽度^[8]、脉搏波强度比^[9]等,进而提高连续血压估计的准确性。随着机器学习的发展,还有学者研究了新的建模方法用于拟合血压模型,如人工神经网络^[10]、随机森林(Random Forest, RF)^[11]、循环神经网络^[12-13]等。2020 年,韩国首尔大学 Yang 等^[14]从心电图(Electrocardiogram, ECG)和光电容积脉搏波(Photoplethysmographic, PPG)中提取

了 42 个特征, 然后利用线性回归、RF、人工神经网络和循环神经网络 4 种机器学习方法, 构建了用于估计血压低频和高频成分的模型。基于手术中采集的数据集, 对该模型进行验证, 结果表明, Yang 等^[14]构建的模型对收缩压(Systolic Blood Pressure, SBP)和舒张压(Diastolic Blood Pressure, DBP)的估计误差分别为 (0.05 ± 6.92) mmHg 和 (-0.05 ± 3.99) mmHg。2022 年, Wang 等^[15]提出基于迁移学习技术的血压测量方法, 将短时 PPG 转换成图片, 并利用训练好的深度卷积神经网络从 PPG 图片中提取特征, 用于血压估计; 在 MIMIC 数据集上对该方法进行验证, 结果显示, 所构建的模型对 SBP 和 DBP 的估计误差分别为 (0.00 ± 8.46) mmHg 和 (-0.04 ± 5.36) mmHg。2022 年, Mieloszyk 等^[16]在大规模穿戴式数据集上, 利用岭回归验证了不同信号(ECG、PPG 和压力脉搏波)估计血压的可行性, 验证结果表明, 与 ECG、PPG 相比, 从压力脉搏波信号中提取的特征对血压的估计误差最低, 对 SBP 和 DBP 的估计误差分别为 (0.32 ± 9.8) mmHg 和 (0.54 ± 7.7) mmHg。然而, 血压影响因素复杂, 现有脉搏波理论无法涵盖多种影响因素, 极易导致测量误差。本文基于 ECG 与 PPG 信号, 引入心阻抗图(Impedance Cardiogram, ICG), 旨在通过特征提取计算出更多反映心血管特性的信息, 探索影响血压测量的关键因素, 进而研究一种基于多特征融合的无袖带血压预测模型, 以提高模型的预测能力及在不同应用场景下的鲁棒性。

2 方 法

2.1 数据采集方案

本研究招募了 55 位健康的成年受试者(排除实验前一天摄入酒精或咖啡的志愿者及有脑血管疾病史的志愿者)。受试者年龄范围为

20~66 岁, 其中有 28 位女性受试者, 27 位男性受试者。本研究通过了中国科学院深圳先进技术研究院伦理委员会的审批, 研究方案符合赫尔辛基宣言的伦理准则。整个实验过程分为平躺(5 min)、正坐(3 min)、深呼吸(2 min)、游戏(3 min)和握力(1.5 min) 5 个状态阶段。实验在安静的环境中进行, 尽量排除外界干扰。实验过程为: (1)受试者在实验床上平躺 5 min, 而后放松 2~3 min; (2)床板自动调节, 受试者转变为正坐状态保持 3 min, 再次进入放松状态; (3)待信号稳定后, 受试者深呼吸 2 min (6 次/min), 再次进入放松状态; (4)待信号稳定后, 受试者进行 3 min 的游戏测试, 引起受试者的紧张情绪; (5)随后继续保持放松状态, 待信号平稳后进入握力实验, 保持最大握力 1.5 min; (6)实验结束, 保存采集的各个状态的多通道生理信号。实验过程中, 采用美国 BIOPAC MP150 型 16 通道电生理信号记录仪采集生理信号, 信号采样频率为 1 000 Hz。其中, ECG100C 模块采集 ECG 信号、PPG100C 模块采集 PPG 信号、EBI100C 模块采集生物电阻抗(Electrical Bio-Impedance, EBI)信号、RSP100C 模块采集呼吸波(Respiration, RSP)信号; 同时, 使用 CNAP 连续血压测量仪采集无创连续血压作为血压参考值。采集方式为: 将 ECG 电极片置于左右手臂和右腿上, 脉搏波传感器夹在食指指尖, EBI 传感器安装在颈部两侧、锁骨下和胸部两侧, 呼吸传感器绑在腰间, CNAP 连续血压测量仪的指套戴于左手中指和食指上, 袖带戴于左上臂。

2.2 信号预处理

为解决心电信号工频干扰和基线漂移问题, 本文设计了一个巴特沃斯带通滤波器, 设置低通截止频率为 5 Hz, 避免基线漂移, 设置其高通截止频率为 30 Hz, 避免工频干扰。在此通带范围内, 可最大程度保留 ECG 信号的主要信息和 R

点等重要特征点。脉搏波信号的主要信息集中在 0~10 Hz, 本文设计了一个一阶巴特沃斯低通滤波器以滤除其工频干扰, 设置滤波器截止频率为 10 Hz。利用 BIOPAC 系统自带的 AcqKnowledge 软件, 对总阻抗图信号求一阶导得到 ICG, ICG 频率分布在 5~10 Hz, 采用巴特沃斯带通滤波器, 设置其低通截止频率为 5 Hz, 高通截止频率为 10 Hz, 避免其低频基线漂移和高频工频干扰, 使信号更光滑、周期性更明显。在采集到的所有周期信号中, 血压是最稳定且受干扰最小的信号, 因此本文选择血压信号作为基准计算其信号周期, 然后基于血压信号的周期序列对其他信号进行分割, 并检测特征点。

2.3 特征提取

如图 1 所示, 对多通道信号进行特征点提取。提取的特征点为: ECG 信号的 R 点和 Q 点, PPG 信号的波谷点 Pv 和波峰点 Pk 及 ICG 的 B 点和 X 点。其中, 脉搏波到达时间 (Pulse Arrival Time, PAT) 定义为同一心动周期内 ECG 信号中的 R 点到 PPG 信号波峰点 Pk 的时间差。PATm 定义为同一心动周期内 ECG 信号中 R 点到 PPG 信号波峰点 Pk 和与波谷点 Pv 之间的时




图 1 多导信号特征点的提取

Fig. 1 Extraction of multiple signal feature points

间中点 Pm 的时间差。射血前期时间 (Pre-ejection Period, PEP) 定义为同一心动周期内 ECG 信号中的 Q 点到 ICG 信号上 B 点的时间差。左心室射血时间 (Left Ventricular Ejection Time, LVET) 定义为同一心动周期内 ICG 信号中的 B 点和 X 点的时间差, PTT 采用 PAT 减去 PEP 方法得出。将提取到的 PTT、PAT、PEP、LVET 等特征进行组合, 计算其比值, 可获得多个新的特征。表 1 为多导生理信号中初步提取的 89 种特征及其说明。其中, 为研究 ICG 信号对血压预测的贡献, 本文针对 ICG 信号进行了大量的特征提取。

本文除了提取几种信号在每一个心动周期内的均值、面积、方差等常见特征外, 还对其他特征进行计算, 具体定义和计算方式如下。

①能量的计算公式如公式 (1) 所示。

$$E = \sum_{i=1}^n |x_i|^2 \quad (1)$$

其中, E 为信号的能量; x_i 为一个心动周期中第 i 个采样点; n 为输入信号一个周期内的采样点数。

②偏度 (Skewness) 的计算公式如公式 (2) 所示。

$$S = \frac{1}{n} \sum_{i=1}^n \left[\left(\frac{x_i - \mu}{\sigma} \right)^3 \right] \quad (2)$$

其中, μ 为信号均值; σ 为标准差; S 为信号的三阶矩, 反映信号概率密度的偏度。

③峰度 (Kurtosis) 的计算公式如公式 (3) 所示。

$$K = \frac{1}{n} \sum_{i=1}^n \left[\left(\frac{x_i - \mu}{\sigma} \right)^4 \right] \quad (3)$$

其中, μ 为信号均值; σ 为标准差; K 为信号的四阶矩, 反映信号概率密度的峰度。

④均方根值 (Root Mean Square) 的计算公式如公式 (4) 所示。

$$x_{rms} = \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2} \quad (4)$$

偏度、峰度及均方根值均可敏感地表现出信

表 1 多导生理信号中提取的 89 种特征

Table 1 89 features extracted from multiple physiological signals

特征	特征说明	特征	特征说明
F1~F3	PPG 信号的峰值、谷值与峰谷差	F42~F45	F26/F21、F27/F23、F28/F24、F29/F25
F4	心率	F46~F49	F38/F22、F39/F23、F40/F24、F41/F25
F5~F6	PTT 及平方值	F50~F53	ICG 信号面积、能量、方差和均值
F7~F8	PAT 和 PATm	F54~F56	ICG 信号峰值、谷值和方差
F9~F11	PTTm、PEP、LVET	F57~F58	ICG 信号偏度和峰度
F12	收缩时间比	F59~F60	ICG 信号峰值和均方根值
F13	PTT/PEP	F61~F64	ICG 信号峰值、波形、脉冲、裕度因子
F14	PEP/LVET	F65~F69	ICG 信号幅度谱最大、最小值、中位数、均值和峰值
F15	PTT/PAT	F70~F73	ICG 信号功率谱最大值、最小值、中位数、均值
F16	PAT/LVET	F74	ICG 信号信噪比
F17	PTT/LVET	F75	ICG 信号占用带宽
F18~F21	ECG 信号面积、能量、方差和均值	F76~F81、F84	按表内顺序出现的信号的模糊熵
F22~F25	PPG 信号面积、能量、方差和均值	F82~F83	F78 和 F77、F81 和 F77 的比值
F26~F29	PPG 信号峰谷间的信号面积、能量、方差和均值	F85	ICG 信号与 PPG 信号的模糊熵比值
F30~F33	EBI 信号面积、能量、方差和均值	F86~F87	ECG 信号互相关函数的最大值和均值
F34~F37	RSP 信号面积、能量、方差和均值	F88~F89	PPG 信号互相关函数的最大值和均值
F38~F41	R-P 点间 PPG 信号面积、能量、方差和均值		

号的一些微小变化, 此外, 本文还引入几种不同的无量纲特征值, 以减少外界物理量的影响, 具体如下:

①峰值因子(Crest Factor)的计算公式如公式(5)所示。

$$C = \frac{x_{\text{peak}}}{x_{\text{rms}}} \quad (5)$$

其中, x_{peak} 为信号的峰值; C 为信号峰值与均方根值的比值, 用以反映波形中信号峰值的极端水平。

②脉冲因子(Impulse Factor)是信号峰值与信号绝对值的均值之间的比值, 与峰值因子的区别在其分母上, 其计算公式如公式(6)所示。

$$I = \frac{x_{\text{peak}}}{x_{\text{arv}}} \quad (6)$$

$$x_{\text{arv}} = \frac{1}{n} \sum_{i=1}^n |x_i| \quad (7)$$

其中, x_{arv} 为信号绝对值的均值(整流平均值)。

③裕度因子(Margin Factor)

$$C_e = \frac{x_{\text{peak}}}{x_r} = \frac{x_{\text{peak}}}{\left(\frac{1}{n} \sum_{i=1}^n \sqrt{|x_i|} \right)^2} \quad (8)$$

$$x_r = \left(\frac{1}{n} \sum_{i=1}^n \sqrt{|x_i|} \right)^2 \quad (9)$$

其中, x_r 为方根幅值。

④波形因子(Shape Factor)是信号有效值与信号绝对值的均值之间的比值, 也是脉冲因子与峰值因子的比值, 其计算公式如公式(10)所示。

$$S_f = \frac{x_{\text{rms}}}{x_{\text{arv}}} \quad (10)$$

此外, 本文还提取了信号的幅度谱^[17]、功率谱及模糊熵^[18]特征。对每段心拍信号进行傅里叶变换, 获得其幅度谱和功率谱; 在连续的心拍中, 按照采集生理信号的时间序列计算其模糊熵, 提取所有信号共 10 个模糊熵的特征(其中 3 个特征为某两种生理信号模糊熵的比值)。

2.4 特征筛选

为进一步筛选特征, 本文将提取的 89 种特

征分别与 SBP、DBP 进行皮尔森相关性系数及最大互信息系数 (Maximal Information Coefficient, MIC) 计算, 分别计算特征与血压的线性相关性 & 非线性相关性, 用 r 表示特征与血压之间皮尔森相关系数的得分。综合考虑两种相关性结果, 筛选出 r 和 MIC 统计得分表现均较好的特征纳入特征优选簇, 如表 2 所示。其中, r 与 MIC 是各个特征与 SBP 相关系数的计算得分。

2.5 血压建模方法

本文利用线性回归、RF 回归和极限梯度提升回归模型进行血压预测, 并将不同方法所得结果进行对比。线性回归 (Linear Regression, LR): $y = \mathbf{w}^T \mathbf{x} + b$ (其中, T 为转置, \mathbf{w} 为参数矩阵), 通过模型训练得到最优的 \mathbf{w} 和 b , 进而使模型的预测值不断逼近真实值。RF 是一种基于树的集成学习方法, 其由大量弱决策树学习器组成, 这些弱决策树并行生长以减小模型的偏差和方差, 从而弥补传统分类和回归树的缺点, 本文设置树的最大深度为 48, 决策树的个数为 512。极限梯度提升 (Extreme Gradient Boosting, XGBoost) 模型通过集成多个弱的学习器, 使用

加法函数学习后得到强的学习器, 用于预测结果, 其中, 树的最大深度设置为 12, 学习率设置为 0.08, 决策树个数设置为 400。

3 实验结果

3.1 不同类型特征的血压预测结果对比

本文选取标准差 (Standard Deviation, STD)、平均绝对误差 (Mean Absolute Error, MAE) 和平均误差 (Mean Error, ME), 作为训练模型测试时的评估指标。此外, 为分析传统血压预测中所用的单特征 (PTT)、本文经特征选择得到的特征优选簇 (Selected) 及提取得到的全部特征簇 (All) 对血压预测的影响, 分别对这 3 类特征进行预测建模。

为对实验中获取的 5 个实验状态进行统一预估, 将所有状态下提取特征簇数据集合并后再进行模型训练。对数据进行分割后, 共得到 27 394 条记录, 本文选取其中的 80% 作为训练集, 20% 作为测试集。对传统血压预测中所用的单特征、本文经特征选择得到的特征优选簇以及提取得到

表 2 特征优选簇

Table 2 Preferred clusters of features

特征	特征说明	r	MIC	特征	特征说明	r	MIC
F6	PTT 平方值	0.259	0.117	F52	ICG 信号方差	-0.330	0.167
F7	PAT	0.186	0.132	F53	ICG 信号均值	0.020	0.047
F8	PATm	0.142	0.098	F55	ICG 信号谷值	0.191	0.083
F9	PTTm	0.211	0.096	F57	ICG 信号偏度	-0.292	0.119
F19	ECG 信号能量	0.406	0.198	F59	ICG 信号峰值	-0.464	0.189
F20	ECG 信号方差	0.424	0.208	F60	ICG 信号均方根值	-0.383	0.160
F21	ECG 信号均值	-0.051	0.063	F61	ICG 信号峰值因子	-0.252	0.099
F31	EBI 信号能量	-0.315	0.260	F66	ICG 信号幅度谱最小值	-0.078	0.048
F32	EBI 信号方差	-0.028	0.010	F70	ICG 信号功率谱最大值	-0.136	0.107
F34	RSP 信号面积	-0.226	0.154	F77	PPG 信号的模糊熵	-0.203	0.105
F35	RSP 信号能量	-0.162	0.156	F79	EBI 信号的模糊熵	-0.181	0.083
F36	RSP 信号方差	-0.111	0.109	F87	ECG 信号互相关函数的均值	0.072	0.059
F51	ICG 信号能量	-0.250	0.184				

的全部特征分别进行 RF 和 XGBoost 模型预测, 预测结果如表 3 所示。

由表 3 可知, 使用特征优选簇后, RF 对于 SBP 和 DBP 两类血压的预测建模效果均较好, 误差指标均为最优结果, 说明本文通过线性和非线性相关分析共同筛选得到的特征优选簇具有一定优化作用, 使用特征优选簇的模型性能优于使用单个或全部特征建立的模型, 拟合度较高, 处于较好的置信区间内。

选择 SBP 预测结果较好的模型, 绘制预测拟合散点图, 如图 2 所示。其中, XGBoost 和 RF 的预测散点图均为使用特征优选簇的结果。

由图 2 可知, 线性回归的拟合性较差, 其预

测回归线偏离参考线较远, 而 XGBoost 和 RF 的预测回归线均贴近于参考线, 两者对于血压预测的拟合度较高。其中, RF 的预测水平更高, 其回归线的贴合度比 XGBoost 更好, 且离群点较少, 其原因可能是 XGBoost 训练过程中易导致梯度爆炸, 使得离群值较多。

3.2 与其他工作对比

为验证本文多特征融合模型的性能, 本文将该模型与其他相关工作进行对比, 结果如表 4 所示。

由表 4 可知, 与梯度提升决策树、U-net 等模型相比, 本文基于多特征融合的随机森林模型预测结果较好, 更适用于临床中要求血压测量精度较高的应用场景。

表 3 三种不同特征的模型预测结果对比

Table 3 Comparison of prediction results of models with three different features

模型	误差指标	SBP (mmHg)			DBP (mmHg)		
		PTT	Selected	All	PTT	Selected	All
LR	MAE	16.35			11.21		
	STD	20.21			14.35		
	ME	−0.15			−0.10		
XGBoost	MAE	16.12	2.80	2.89	10.90	1.96	2.04
	STD	19.89	4.28	4.34	14.14	2.86	3.05
	ME	−0.21	0.13	0.21	0.06	0.11	0.19
RF	MAE	16.28	2.56	2.74	10.99	1.91	2.08
	STD	20.09	4.06	4.34	14.18	2.80	3.24
	ME	−0.16	−0.06	−0.08	−0.11	−0.03	−0.03

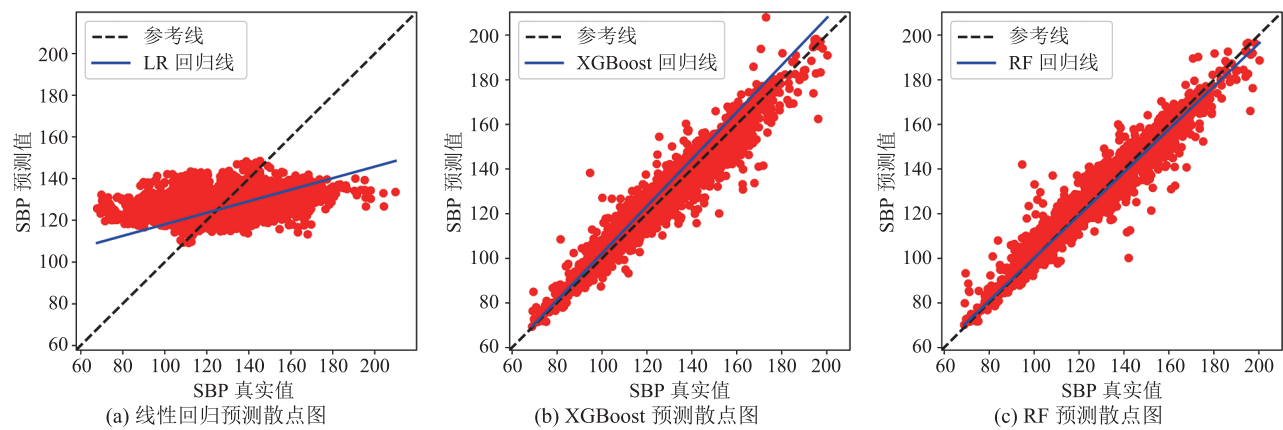


图 2 3 种机器学习模型的预测散点图

Fig. 2 Predictive scatter plots for three machine learning models

表 4 相关工作的对比

Table 4 Comparison of related work

算法	信号	SBP (mmHg)		DBP (mmHg)	
		MAE	STD	MAE	STD
线性回归 ^[19]	PPG	14.71	10.79	6.74	6.11
U-net ^[20]	PPG	3.68	4.42	1.97	2.92
卷积神经网络 ^[21]	PPG、ECG	3.09	2.76	2.11	2.00
梯度提升决策树 ^[22]	PPG	3.75	5.46	3.10	3.93
RF (本文)	PPG、ECG、ICG、RSP	2.56	4.06	1.91	2.80

4 讨论与分析

血压的变化受多种因素影响,如外周阻力、血管弹性、血容量、心排量等。常用的 PTT 模型本质上仅反应血管的硬度,无法涵盖影响血压变化的多种因素。本文在以 PTT 为特征的传统一元线性回归模型的基础上,引入生理意义上与血压变化具有一定关联的 ICG。从生理角度分析,人体心脏在周期泵血过程中,人体不同部位的 ICG 会发生同样的周期性变化,可通过 ICG 的波形变化图,计算出心排量和相关的血流动力学参数。而每搏射血量和心排量是血压和心血管系统的重要参数,因此 ICG 会对血压预测作出一定贡献。本文从线性与非线性相关性角度进行分析,提取得到大量与血压相关性较高的 ICG 特征,使用不同特征预测的结果表明,利用特征筛选后的特征优选簇可提高机器学习模型性能。与使用单个或全部特征建立的模型相比,其模型预测误差更小。

为验证本文特征优选簇在血压预测方面的性能,本文将传统线性回归模型与机器学习模型进行对比。研究过程中发现,血压变化的影响因素极为复杂,具体机理并不明确,由外周阻力等心血管系统中所有的因素共同作用,简单的线性模型具有很大程度的局限性和不足。为更好地对血压建模,进行临床连续、无创血压预测,本文对比了不同类型的机器学习模型。由对比结果可

知,RF 模型基于特征优选簇的血压预测建模效果较好。与 RF 模型相比,XGBoost 模型的性能则略差,原因可能是 XGBoost 在空间上消耗多、时间代价大,但其预测水平仍然较高,所有误差指标较低,接近于 RF 模型的结果,属于较好的模型。本文研究的两种机器学习方法 XGBoost 和 RF 在使用特征优选簇后,模型误差均低于 AAMI 标准误差范围($ME < \pm 5 \text{ mmHg}$, $STD < 8 \text{ mmHg}$)。与其他文献工作相比,本文提出的多特征融合模型具有优越性。

在不同生理状态的血压预测分析中,本文仅招募了 55 名志愿者进行生理信号采集,得到的数据量偏小。且本文的模型属于较短时间内的血压预测模型,对于长时间的血压预测,其预测效果有待进一步研究和验证。在未来的研究中,应该增加受试者数量,同时采集更长时间的生理信号,以期建立更有说服力的模型。

5 结 论

针对基于脉搏波和心电信号的血压预测模型预测误差大的问题,本文提出了基于多特征融合的血压预测模型,结合与血压相关性较高的 ICG,通过线性和非线性分析,选取特征集合中与血压相关性较高的特征组成特征优选簇,利用传统的一元 PTT 线性模型、XGBoost 模型及 RF 模型,将所有实验阶段状态下的多维度特征优选

簇合并输入, 构建适用于多种状态的血压估计模型。然后, 对不同的机器学习模型的 MAE、STD 及 ME 指标进行评估。结果表明, RF 算法更适用于本文建模, 与一元 PTT 特征以及所有特征相比, 特征优选簇作为输入的模型预测效果更好, 说明经过特征筛选后的特征优选簇提高了机器学习模型的性能。最后, 通过与其他相关工作进行对比, 证明了本文提出的多特征融合的血压建模方法不仅准确性较高, 而且可应用于不同状态场景, 具有一定的鲁棒性。

参 考 文 献

- [1] Ackland GL, Brudney CS, Cecconi M, et al. Perioperative quality initiative consensus statement on the physiology of arterial blood pressure control in perioperative medicine [J]. *British Journal of Anaesthesia*, 2019, 122(5): 542-551.
- [2] Eley VA, Christensen R, Guy L, et al. Perioperative blood pressure monitoring in patients with obesity [J]. *Anesthesia & Analgesia*, 2019, 128(3): 484-491.
- [3] Maheshwari K, Nathanson BH, Munson SH, et al. The relationship between ICU hypotension and in-hospital mortality and morbidity in septic patients [J]. *Intensive Care Medicine*, 2018, 44(6): 857-867.
- [4] Wesselink EM, Kappen TH, Torn HM, et al. Intraoperative hypotension and the risk of postoperative adverse outcomes: a systematic review [J]. *British Journal of Anaesthesia*, 2018, 121(4): 706-721.
- [5] Saugel B, Sessler DI. Perioperative blood pressure management [J]. *Anesthesiology*, 2021, 134(2): 250-261.
- [6] Abbott TEF, Howell S, Pearse RM, et al. Mode of blood pressure monitoring and morbidity after noncardiac surgery: a prospective multicentre observational cohort study [J]. *European Journal of Anaesthesiology*, 2021, 38(5): 468-476.
- [7] Chen Y, Shi S, Liu YK, et al. Cuffless blood-pressure estimation method using a heart-rate variability-derived parameter [J]. *Physiological Measurement*, 2018, 39(9): 095002.
- [8] El-Hajj C, Kyriacou PA. Deep learning models for cuffless blood pressure monitoring from PPG signals using attention mechanism [J]. *Biomedical Signal Processing and Control*, 2021, 65: 102301.
- [9] Ding XR, Zhang YT, Liu J, et al. Continuous cuffless blood pressure estimation using pulse transit time and photoplethysmogram intensity ratio [J]. *IEEE Transactions on Biomedical Engineering*, 2016, 63(5): 964-972.
- [10] Priyanka KNG, Chao PCP, Tu TY, et al. Estimating blood pressure via artificial neural networks based on measured photoplethysmography waveforms [C] // *Proceedings of the 2018 IEEE Sensors*, 2018: 1-4.
- [11] Chen XH, Yu SY, Zhang YF, et al. Machine learning method for continuous noninvasive blood pressure detection based on random forest [J]. *IEEE Access*, 2021, 9: 34112-34118.
- [12] Senturk U, Polat K, Yucedag I. A non-invasive continuous cuffless blood pressure estimation using dynamic recurrent neural networks [J]. *Applied Acoustics*, 2020, 170: 107534.
- [13] Su P, Ding XR, Zhang YT, et al. Long-term blood pressure prediction with deep recurrent neural networks [C] // *Proceedings of the 2018 IEEE EMBS International Conference on Biomedical & Health Informatics*, 2018: 323-328.
- [14] Yang S, Sohn J, Lee S, et al. Estimation and validation of arterial blood pressure using photoplethysmogram morphology features in conjunction with pulse arrival time in large open databases [J]. *IEEE Journal of Biomedical and Health Informatics*, 2021, 25(4): 1018-1030.
- [15] Wang WN, Mohseni P, Kilgore KL, et al. Cuff-Less blood pressure estimation from photoplethysmography via visibility graph and transfer learning [J]. *IEEE Journal of Biomedical*

- and Health Informatics, 2022, 26(5): 2075-2085.
- [16] Mieloszyk R, Twede H, Lester J, et al. A comparison of wearable tonometry, photoplethysmography, and electrocardiography for cuffless measurement of blood pressure in an ambulatory setting [J]. IEEE Journal of Biomedical and Health Informatics, 2022, 26(7): 2864-2875.
- [17] 张登奇, 杨慧银. 信号的频谱分析及 MATLAB 实现 [J]. 湖南理工学院学报(自然科学版), 2010, 23(3): 29-33.
- Zhang DQ, Yang HY. Analysis of signal spectrum and realization based on MATLAB [J]. Journal of Hunan Institute of Science and Technology (Natural Sciences), 2010, 23(3): 29-33.
- [18] Chen WT, Wang ZZ, Xie HB, et al. Characterization of surface EMG signal based on fuzzy entropy [J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2007, 15(2): 266-272.
- [19] Kachuee M, Kiani MM, Mohammadzade H, et al. Cuffless blood pressure estimation algorithms for continuous health-care monitoring [J]. IEEE Transactions on Biomedical Engineering, 2017, 64(4): 859-869.
- [20] Athaya T, Choi S. An estimation method of continuous non-invasive arterial blood pressure waveform using photoplethysmography: a U-net architecture-based approach [J]. Sensors, 2021, 21(5): 1867.
- [21] Yan C, Li ZQ, Zhao W, et al. Novel deep convolutional neural network for cuff-less blood pressure measurement using ECG and PPG signals [C] // Proceedings of the 2019 41st Annual International Conference of the IEEE Engineering in Medicine and Biology Society, 2019: 1917-1920.
- [22] Yan JJ, Cai XL, Zhu GY, et al. A non-invasive blood pressure prediction method based on pulse wave feature fusion [J]. Biomedical Signal Processing and Control, 2022, 74: 103523.